

糖尿病不平衡视网膜病变分级的注意阻滞

● 另外还有贺、李涛、李宁、王凯、IEEE会员、IEEE高级会员傅华珠

摘要: 糖尿病性视网膜病变 (DR) 的分级具有挑战性, 因为存在类内变异、小病变和数据分布不平衡。解决细粒度DR分级的关键是找到更细微视觉差异的鉴别特征, 如微动脉瘤、出血和软渗出物。然而, 使用传统的卷积神经网络 (CNNs) 很难识别出较小的病变, 而DR数据分布的不平衡会导致该模型失效

过分关注样本较多的DR评分, 严重影响了最终的评分性能。在本文中, 我们将重点讨论开发一个关注模块来解决这些问题。具体来说, 对于不平衡的DR数据分布, 我们提出了一种新的类别注意块 (CAB), 它探索了每个DR等级的更具区别性的区域特征, 并平等地对待每个类别。为了获取更详细的小病变信息, 我们还提出了全局注意块 (GAB), 它可以利用详细的和不属于类别的全局注意特征图进行眼底图像。通过用主干网络聚合注意块, 构建CABNet进行DR分级。注意块可以应用于广泛的主干网络, 并以端到端方式有效地训练。在三个公开的数据集上进行了全面的实验, 表明CABNet用很少的额外参数为现有的最先进的深度架构产生了显著的性能改进, 并实现了最先进的DR分级结果。代码和型号将可在

<https://github.com/he2016012996/CABnet>.

索引术语-糖尿病视网膜病变分级、注意机制、类别注意阻滞 (CAB)、全局注意阻滞 (GAB)。

1. 介绍

DR是一种由糖尿病引起的微血管并发症, 它是世界上[1]中导致失明和视力损害的主要原因, 有三分之一的糖尿病患者出现糖尿病

稿件于2020年8月15日收到; 2020年9月7日接受。出版日期为2020年9月11日; 当前版本的日期为2020年12月29日。这项工作是由国家自然科学基金资助61872200, 部分由自然科学基金会天津资助19JCZDJC31600和授予18YFYZCG00060, 部分开放项目基金的国家重点实验室的计算机架构, 计算技术研究所, 中国科学院, 授予CARCH201905。(通讯作者: 王凯)

他、李涛、李宁、王凯在南开大学计算机科学学院, 天津300350(电子邮件: 健康2020@163.com; litao@nankai.edu.cn; 内村1994@mail.nankai.edu.cn; wangk@nankai.edu.cn)。

华住于阿联酋阿布扎比人工智能研究所 (IIAI) (电子邮件: hzfu@ieee.org)。

本文中一个或多个数字的颜色版本可以在<https://ieeexuch>上找到。ieee.org.

数字对象标识符10.1109/TMI.2020.302346

[2]博士的迹象。DR的主要病理特征为微动脉瘤、出血、软渗出物和硬渗出物。根据眼底图像中病变的类型和数量, DR可分为5个阶段: 无DR、轻度DR、中度DR、重度DR和增殖性DR [3]。如果长期保持病理状态的话, 视网膜上的部分血管就会被阻塞, 最终导致严重的视力损害甚至失明。因此, 对DR的严重程度进行分级很重要, 使DR患者能够在早期得到正确及时的治疗。

由DR引起的失明可以通过定期的眼底检查来预防。在临床诊断中, DR筛查主要依赖于眼科医生检查彩色眼底图像。然而, 大量的DR患者给有限的眼科医生带来了巨大的负担。随着糖尿病患者数量的增加, 眼底图像的数量越来越增加, 手工实时分析越来越困难。因此, 有必要使用计算机辅助诊断来减少眼科医生的负担和检查时间, 使患者及时了解自己的疾病。

中枢神经网络近年来取得了巨大的进展, 并在计算机视觉领域得到了广泛的应用。cnn以端到端方式将特征提取与分类端到端相结合, 在图像分类[4]、目标检测[5]和语义分割[6]等任务上取得了重大突破。由于cnn具有强大的高级特征提取能力和表征能力, 它们也被广泛应用于视网膜血管分割[7]、视盘分割[8]、青光眼筛查[9]、[10]等医学图像分析任务中。在DR分级中, Li等人。[11]采用基于迁移学习的预训练的cnn进行DR分级。具体来说, 他们将预先训练好的cnn作为特征提取器, 并使用最后一个全连接层的输出作为特征, 结合支持向量机 (SVM) 来解决分级任务。杨等人。[12]提出了一种两阶段CNN从眼底图像中检测病变和分级DR, 取得了良好的效果。该方法采用两阶段的方法解决DR分级, 比一阶段策略更复杂。

虽然基于cnn的DR分级方法取得了良好的效果, 但由于任务的复杂性, 其实际临床应用仍具有挑战性。首先, 这五个DR等级在颜色和纹理上非常相似, 因此很容易在评分任务中混淆它们。这对阶级间的多样性产生了不利影响。第二, 眼底图像中的一些病变非常小, 并且只有几个像素组成, 如图所示

0278-0062©2020。允许个人使用, 但再版/再分发需要IEEE的许可。

看到<https://www.ieee.org/publications/rights/index.html>获取更多信息。

授权许可使用仅限于: NANKAI大学。已于2022年10月10日07: 54: 20日从IEEE Xplore下载。限制适用。




图1. 一个眼底图像上有小病变的例子。原始图像和标注的图像分别在左边和右边。绿色、红色、蓝色和浅蓝色的边界框分别代表硬渗出物、微动脉瘤、出血和软渗出物。

在无花果。1. 这些在卷积过程中很可能被忽略, 因此对最终的DR分级结果有害。第三, 由于异常的眼底图像只占一小部分, 因此不同级别间的DR数据分布极为不平衡。图2显示了三个DR分级数据集的数据分布。数据分布的数据分布会导致模型关注样本较多的DR等级 (DR 0和DR 2), 而忽略样本较少的等级 (DR 1、DR 3和DR 4), 这将影响模型的泛化能力。第四, 我们期望特征映射的每个通道代表一个特定的特征模式, 并在不同的DR等级上表现出不同的行为, 从而有利于不同类别的区分。然而, 现有CNN模型中的一些通道要么缺乏类间的多样性, 要么在特征图[13]中存在冗余, 这将限制CNN的表征能力。这四个问题使得DR分级仍然是一项具有挑战性的任务, 只有图像级别的监督。

基于上述观察结果, 我们引入了一个新的注意模块, 它仅使用图像级的监督为DR分级生成更多的特征。对于第一个和第二个问题, 我们提出了受[14]启发全局注意块 (GAB), 它可以学习类别不可知的全局注意特征, 并在眼底图像中保留详细的病变信息, 同时抑制无用信息 (相似的颜色和纹理)。对于后两个问题, 简单而有效的类别注意块 (CAB) 可以学习类别特定的特征, 并扩大不同的DR等级水平之间的距离。更具体地说, 我们假设有固定数量的特征信道来代表每个DR等级, 并且属于同一类的所有特征信道都是具有区别性的, 这将减少特征信道的冗余。如果某个DR等级的数据量有限, CAB可以将重点放在这个DR等级上, 其特定于类的特征通道可以学习鉴别特征, 解决数据分布不平衡的问题。我们将这两个提出的块嵌入到一个主干网络中, 产生了一个新的DR分级模型, 称为CABNet, 它可以帮助cnn在一些额外参数下学习DR分级的区别表示。我们的主要贡献总结如下:

- (1) 提出了一种新的类别注意块 (CAB) 来探索不同的区分区域级特征

以特定类别的方式对待每个DR等级, 并平等地对待每个DR等级, 减少了特征冗余和数据分布不平衡对DR等级的影响。此外, CAB还关注于类别注意, 这是对通道和空间注意的补充, 因此CAB可以与其他非类别注意块相结合, 以进一步改进DR分级的性能。

- (2) 通过组合两个互补的块, i. e. DR分级建议采用GAB和CAB、CABNet进行分级。CABNet可以捕获详细的小病变特征, 有助于DR分级, 缓解数据分布不平衡的问题。
- (3) 提出的注意模块是通用即插即用CNN模块, 可用于任何主干, 显著提高DR评分性能。
- (4) 在三个公共数据集上进行了广泛的实验。e. DDR, Messidor和EyePACS, 以验证建议的CABNet的有效性。消融研究表明, CAB不仅显著提高了DR分级的性能, 而且与GAB和其他注意块 (CBAM (CBAM) 注意模块) 和GC) 具有高度的互补性。此外, 在与其他DR分级方法的比较实验中, CABNet在二进制类和多类DR分级任务中都取得了最先进的结果。

本文的其余部分组织如下。第二节分析了DR分级和注意机制的相关工作。DR分级的CABNet。第四节进行了大量的实验来评估CABNet的DR分级性能, 并在三个数据集上将CABNet与其他方法进行了比较。讨论和结论分别列在第五节和第六节中。

II. 相关工程

在本节中, 我们简要回顾最近在深度学习中DR分级和注意机制的工作。

A. 对DR分级的深度学习

近年来, 利用深度学习算法在医学分析领域取得了显著进展。深度学习, 特别是cnn, 为DR分级提供了强有力的支持[1517]。具体来说, CNN可以以端到端的方式被训练为特征提取器, 它可以直接从眼底图像中识别出细微的特征, 而不需要人工的努力或特定的领域知识。范·格林斯文等人。[18]提出了一种选择性采样方法, 通过在训练过程中动态选择错误分类的阴性样本, 加快了彩色眼底图像出血检测的训练速度。Vo和Verma [19]设计了一种新的深度网络, 利用多个滤波器大小学习细粒度特征, 在两个公共数据集上进行DR识别, 并取得了良好的效果。古尔山等。[20]应用




图2. 三个DDR分级数据集、Messidor和EyePACS数据集的数据分布不平衡。

启动-v3架构用于在视网膜眼底图像中自动检测糖尿病视网膜病变和糖尿病黄斑水肿, 取得了良好的效果。以往的研究表明, 基于深度学习的方法对DR评分任务是有效的。然而, 由于传统的深度学习模型难以捕捉到小病变, 这仍然具有挑战性。

B. 深度学习中的注意机制

注意机制有助于捕获大多数计算机视觉任务中的细粒度特征, 并已广泛应用于图像分类[21]、[22]、对象定位[23]和语义分割[24]、[25]。周等人。[26]提出了一种多细胞体系结构, 逐步提高了cnn的深度和输入图像的分辨率, 减少了训练时间, 提高了分类性能。为了进一步提高筛查性能, 他们利用注意机制对眼底图像进行DR筛查。王等人。[27]提出了一种基于CNN的算法, 其注意机制是基于小的高分辨率补丁, 同时诊断DR和突出可疑区域。李等人。[28]使注意力映射成为端到端训练的一个明确而自然的组成部分, 它可以无缝地弥合使用弱监督和额外监督之间的差距, 他们的注意力模块在语义分割方面取得了良好的效果。在细粒度图像分类中, Ding等人。[29]应用具有自上而下特征路径和自下而上注意路径的注意金字塔卷积神经网络来增强特征表征, 准确定位区分区域。这些方法可以在不需要额外监督的情况下进行端到端训练, 并学习输入图像的高级语义和低级详细特征表示。然而, 虽然他们已经取得了良好的结果, 但他们没有考虑到不平衡的数据分布。基于这些之前的工作, 我们提出了一个注意模块, 它将通道、空间和类别方面的注意聚合为细粒度的DR分级。我们的注意力模块相对简单但有效, 并在DR评分任务上工作良好。

最近的两篇研究成果都集中在不平衡的问题上数据分布戴等人。[30]提出了一种多筛卷积神经网络 (MS-CNN) 来提高微动脉瘤区域的识别, 该网络融合了诊断报告中的低级图像特征和高水平文本信息。实验结果表明, 通过整合专家领域知识, 可以缓解数据分布不平衡的问题。对于不平衡的病变检测任务, Zhuang等人。[31]提出CARE来提高对小病的关注, 从而提高对罕见病的分类性能。然而, 为了使CARE更注意小班的病变区域, 少数班在训练时需要额外的边界框标注。与MS-CNN和CARE相比, 所提出的CABNet有两个优点。一方面, CABNet只需要图像级的监督信息, 而不需要MS-CNN中的临床报告和CARE中的边框注释等额外信息。另一方面, 提出了一个注意模块来处理CABNet中不平衡的数据分布, 它可用于任何主干网, 以提高DR分级性能。

III. 方法学

CABNet的结构, 如图所示。3、由四个部分组成。e. 主干, GAB, CAB和分类器。GAB和CAB构成注意力模块, CABNet以端到端的方式进行训练。在本节中, 我们首先概述了CABNet, 它有效地集成了GAB和CAB, 以提高DR分级的性能。然后, 我们详细地说明了所提出的GAB和CAB。

A. CABNet概述

1) 结构: 如图所示。3、CABNet以眼底图像为输入, 以主干网络为特征提取器, 获得全局特征图。我们可以采用任何在ImageNet [32]上预训练的cnn作为骨干网络来提取特征图 $F \in \mathbb{R}^{h \times w \times c}$ 从最后一个卷积层开始, 其中包含眼底图像的高级语义特征, 其中H、W和C分别表示特征图中通道的高度、宽度和数量。

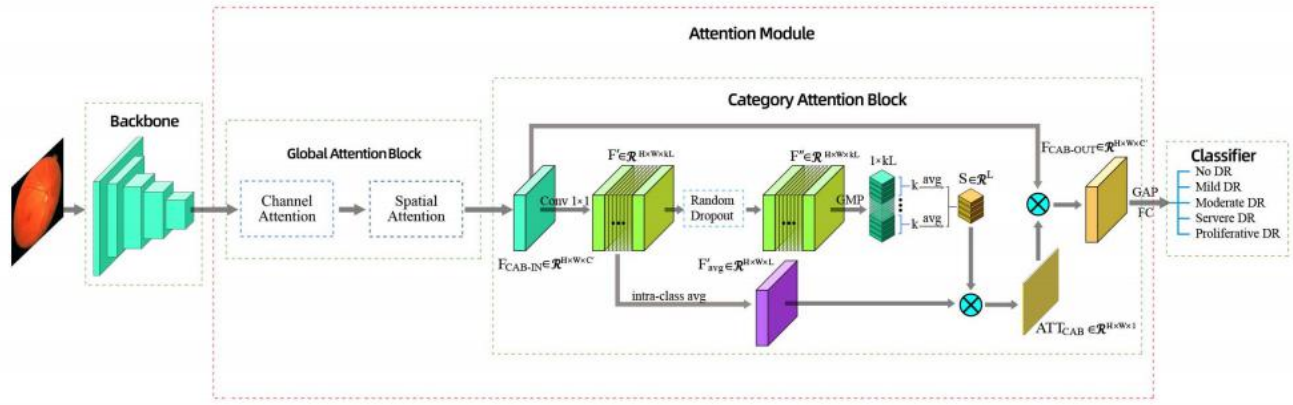


图3. CABNet的整体结构。它由四个部分组成。e. 主干，全局注意块，类别注意块和一个分类器。请注意，主干网络最后一个卷积层的特征图首先被输入到 1×1 卷积层，以减少输入通道并获得 F_{deses} （为了简单起见，我们在结构中省略了这个简单的操作）。然后， F_{deses} 减少作为GAB的输入，空间注意的输出为CAB的输入。最后，将CAB的输出输入分类器进行DR分级。

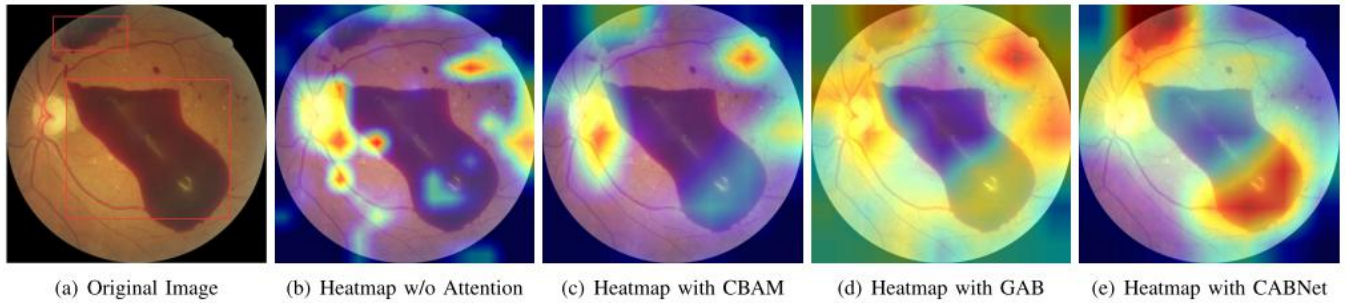


图4. 从DDR数据集的眼底图像的热图可视化。红色的边框表示病变区域。

接下来，为了降低计算成本和内存使用，我们在 F 上应用一个 1×1 的卷积层进行信道缩减并得到 $F_{luse} \in r_h \times w \times c$ 在哪里 $c = C/2$ ，这是GAB的输入。然后，GAB学习通道方向和空间方向的注意特征图 f_{gab} 出保存更详细的小病变信息，抑制较少有用的信息。下一个的 f_{gab} 出作为CAB的输入，迫使网络学习每个DR等级的不同的区分性区域特征，并产生输出 f_{cab} 出。CAB与GAB兼容，它们被连接在CABNet的注意模块中。最后，我们使用全局平均池化（GAP）层和全连接（FC）层来执行分类任务，预测每个输入图像的类标签。

2) 分析：CABNet可以通过将GAB和CAB纳入任何骨干网络来构建。CABNet有三个主要特征。

首先，GAB和CAB是两个完全不同的注意块，其中GAB集中于通道注意和空间注意，CAB专注于类别注意。因此，通过结合这两个块，CABNet可以提高DR分级的性能。

其次，CABNet使用CAB以类别级的方式生成特定于类别的注意特征图。因此，CABNet可以捕获更详细的（GAB）特征和类别级（CAB）特征，更适合于DR分级任务中的不平衡数据集。

第三，CABNet采用为DR分级任务设计的单分支GAB，并基于GAB生成的注意力特征图应用CAB。随着更好的类别不可知的全局注意特征图，CAB对DR分级有了显著的改进。

为了直观地观察CABNet的优势，我们在图中比较了热图。4. 我们可以看到，没有注意的主干忽略了很多病变信息。采用CBAM后，该网络可以捕获更多的病变信息，但仍会遗漏一些信息（中心部分）。当主干与GAB结合时，网络保留了详细的全局注意特征，因此CABNet可以突出更多的信息区域进行DR分级。

B. 全球关注点

1) 结构：GAB由通道注意和空间注意组成，在CBAM [14] 中采用了单分支结构，而不是双分支结构。实验结果表明，与CBAM [14] 相比，GAB更适合用于DR分级任务。其结构如图所示。5. GAB采用了简化的特性 $F_{luse} \in r_h \times w \times c$ 作为输入和学习类别不可知的全局注意特征图。

首先，我们计算了通道注意特征图按照原稿 $_{att} \in r_h \times w \times c$ 通过以下公式：

$$\text{按照原稿}_{att} = (\sigma(\text{Con02}(\text{GAP}(F_{GAB-IN}))) \otimes f_{gab}) \text{ 在, } (1)$$




图5. 整体注意块（GAB）的整体结构。

其中 σ 表示Sigmoid函数，GAP为全局平均池化层，Conv2表示两个 1×1 的卷积层， f_{gab-} 在 F_{deses} ， \otimes 表示元素级乘法。

然后，我们计算GAB的输出。e. 空间注意特征图 f_{gab-} 出，计算公式如下：

$$f_{gab-} \text{ 出} = \text{按照原稿_att} \otimes (\sigma(C_GAP(F_c \text{ att}))), (2)$$

其中， C_GAP 表示跨信道平均池化。 f_{gab-} 出作为CAB的输入，i. e. f_{cab-} 英寸，生成类别注意特征图。

2) 分析：对于通道注意，它通过学习通道注意权重，在通道上作为特征选择器，表明每个特征通道的重要性，抑制信息较少的通道。对于空间注意，它通过学习空间注意权重来指出每个空间位置的重要性，这是对通道注意的补充。对于注意模块的顺序排列，我们将GAB放在CAB之前，以提取全局详细的病变信息，保留更多的小病变区域，从而减少信息的丢失。CAB更注重区分区域，并细化了GAB产生的特征。如果我们改变两个区块的顺序，CAB将丢失一些详细的信息，这将对最终的结果产生不利影响。

C. 类别注意块

1) 结构：CAB的结构如图所示。3. CAB旨在从眼底图像中学习鉴别区域，以增强具有L类的细粒度DR分级任务。对于一个传入的特征贴图 f_{cab-} 英寸 $\in r_h \times w \times c$ ，我们首先将它输入到一个 1×1 的卷积层来生成特征映射 $F \in \text{右侧} \times \text{宽} \times \text{宽}$ ，其中k为检测每个类的鉴别区域所需的通道数。为了迫使一个类内的所有k个特征映射学习不同的区别区域，我们在训练过程中随机删除一半的特征，并将它们的值设置为零，然后我们可以得到 $F \in \text{右侧} \times \text{宽} \times \text{宽}$ ，它保留了每个特征图中的一半特征。在推理过程中，我们去掉了退出操作，并使用k个特征图中的所有特征进行预测。然后，我们计算分数 $S = \{S_1, S_2, \dots, S_L\}$ ，计算公式如下：

$$S_i = \frac{1}{k} \sum_{j=1}^k GMP(f''_{i,j}), \quad i \in \{1, 2, \dots, L\}, \quad (3)$$

其中，GMP表示全局最大池化，和 $f_{i,j}$ 表示中的第i个类的第j个特征映射 $F \setminus \setminus$ 。 $\setminus \setminus$ 测量每个类的特征映射的重要性。

请注意，CAB应该与全局注意块兼容，以便通过结合两种互补类型的块可以更好地完成DR分级。S不直接用作类别注意，并采用类别级跨信道平均池操作 F 来获取每个类的特征映射：

$$F_{i \setminus \setminus \text{avg}} = \frac{1}{k} \sum_{j=1}^k f_{i,j}, \quad i \in \{1, 2, \dots, L\}, \quad (4)$$

其中 $f_{i,j}$ 表示中的第i个类的第j个特征映射 $F \setminus \setminus$ 和 $F_{i \setminus \setminus \text{avg}} \in r_h \times w \times 1$ 表示第i个类的语义特征映射。

然后，类别关注 $\text{司机室} \in r_h \times w \times 1$ 取得如下结果：

$$\text{司机室} = \frac{1}{L} \sum_{i=1}^L S_i F_{i \setminus \setminus \text{avg}} \quad (5)$$

司机室 突出了为DR分级提供信息的鉴别区域。最后，特征映射 f_{cab-} 英寸可以转换为特征地图吗 f_{cab-} 出按类别关注在TCAB：

$$f_{cab-} \text{ 出} = f_{cab-} \text{ 英寸} \otimes \text{司机室}, \quad (6)$$

其中， \otimes 表示元素级乘法，和 f_{cab-} 出是CAB的输出特征图，它增强了鉴别区域在 f_{cab-} 英寸DR分级。

2) 分析：CAB有三个特点。

首先，CAB以一种类别级的方式学习注意，每个DR类别都被平等地对待。在传统的CNN中，所有的特征图都没有区别地叠加在一起，这可能会导致不同类别之间的信息混淆，对样本较少的类别的关注较少。对于所提出的CAB，它为每个DR类别分配一定数量的特征信道，并保证每个DR等级具有相同的特征信道，有利于避免信道偏差，扩大不同DR类别之间的距离。因此，CAB可以有效地缓解DR分级数据集中广泛存在的数据分布不平衡的问题，如图所示。2. 实验结果进一步支持了这一点。

其次，CAB对每个DR类别比其他cnn挖掘更有区别的区域，这减少了特征冗余，使其完全不同于其他全局注意块，如通道注意和空间注意。因此，CAB是对这些全局注意块的补充，并将它们结合起来，有利于提高DR评分的性能。

第三，CAB生成具有少量参数的注意特征，可以降低计算成本和内存使用。它将每个类别的区分区域集成到一个特征图中，并与输入的特征图具有相同的宽度和高度。因此，CAB和其他全局注意块的结合易于实现。

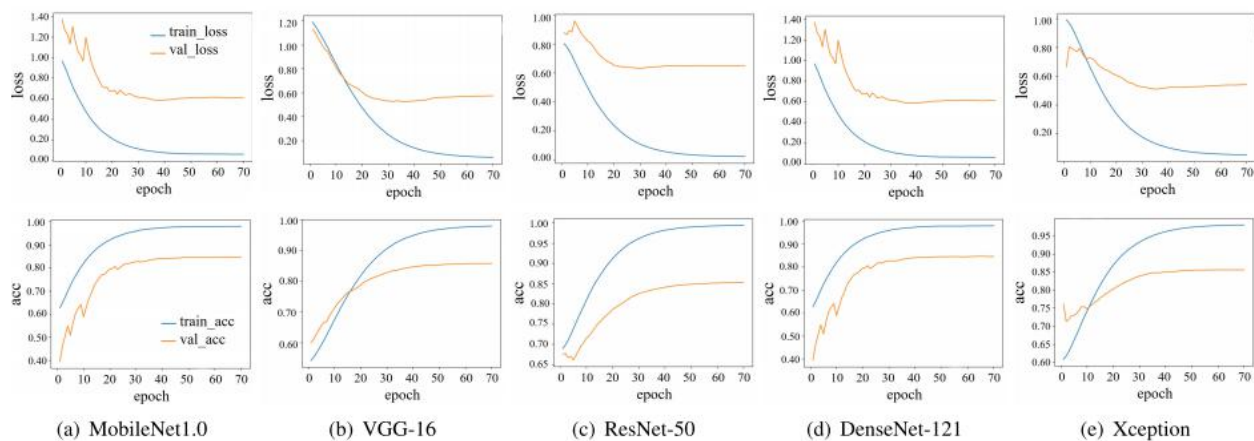


图6. 在DDR数据集上的训练曲线(顶部: 损失vs. 时代, 底部: 准确性vs. 轮train_loss和val_loss分别表示训练集和验证集上的损失。train_acc和val_acc分别表示在训练集和验证集上的精度。这可以从损失和损失。在epoch曲线中, 所有模型都能在70个周期内收敛, 得到了在验证集上损失最小的最优模型。

为了直观地观察CAB的优势, 图中提供了没有/有CAB的模型生成的热图。分别为4 (d)和(e)。红色的边框表示病变区域。可以看出, CAB学习与病变信息相关的鉴别区域, 并突出更准确和信息更丰富的DR分级区域。

增值实验

在本节中, 我们首先介绍常用的DR分级数据集、实现细节和评价指标, 然后给出该方法在三个DR分级数据集上的定性和定量结果。

A. 数据集

DDR DataSet [33]: 该数据集包含13,673张眼底图像, 其中包括6,835张训练图像, 2,733张验证图像和4,105张测试图像。这些图像由7名训练有素的评分者根据国际糖尿病视网膜病变分级分为6个类别。没有明显可见病变的低质量图像被认为是不可分级的。因此, 有六个水平: 无DR、轻度DR、中度DR、重度DR、增殖性DR和不可分级。在我们的实验中, 我们只关注DR分级的五类分类任务; 也就是说, 我们不使用属于不可分级的图像。结果表明, 训练、验证和测试图像分别为6320、2503和3759。

中间数据集[34]: 该数据集集中有1200张眼底图像, DR根据严重程度分为四类, 这与国际标准不一致。它还包含DME (糖尿病性黄斑水肿) 标签, 并被分为三类来测量黄斑水肿的风险。为了与以前的工作进行公平的比较, 我们在这个数据集中对DR分级进行了二进制分类。我们将DR 0和DR 1归类为可引用的, 并根据不可引用的工作[19, 33], 将DR 2和DR 3分组为不可引用的。

EyePACS数据集[36]: 这是最大的DR分级数据集, 由35,126张训练图像和53,576张测试图像组成。每张图像都标有一个DR等级

从0到4。这个数据集的挑战是它在分辨率、强度和数量上的巨大变化。

B. 实施细节

我们的CABNet是基于一个在大规模图像数据集上预先训练的骨干网络。我们应用随机水平翻转、垂直翻转和随机旋转作为数据增强的形式, 以减少过拟合, 我们的网络的输入分辨率为 512×512 。初始学习速率被设置为0.005, 如果在三个时期内不能提高验证数据集上的性能, 则会衰减0.8倍。所有的模型都用Adam优化器和交叉熵损失函数进行了70个时期的训练。对于每个主干, 选择在验证集上表现最好(损失最小)的模型作为最终模型。图中的训练曲线。6证明了该模型可以在70个周期内收敛。批量大小为16, CAB中的k设置为5。我们的框架是使用张力流后端用Keras实现的。所有实验都在NVIDIA GTX 1080Ti GPU上进行, 有11 GB内存。

C. 评价指标

为了评估所提出的方法的性能, 我们采用了精度、二次加权Kappa评分[36]、曲线下面积(AUC)、精度、召回率和f1评分。对于二进制DR分级任务, 我们使用精度、AUC、精度、召回率和F1-Score指标, 对于多类DR分级, 我们使用精度和二次加权Kappa指标。

D. DDR数据集上的消融研究

我们进行了消融研究, 以更好地了解CABNet各成分的影响。首先以MobileNet1.0 [46]为骨干, 分析了CAB和GAB对DDR数据集的影响, 然后分别讨论了CABNet中k的选择、CABNet对不同不平衡比的影响以及CABNet中辍学率的选择。最后, 我们采用其他最先进的CNN架构作为骨干来评估CABNet的通用性。

表I

采用移动网络1.0为主的卡网消融研究
DDR数据集的基线。ACC和KAPPA评分是
在此表中报告了。#Para表示
参数的数量

Method	Acc	Kappa	$\delta acc/\%$	#Para
baseline	0.7318	0.6683	-	3.23M
baseline+SE [37]	0.7384	0.7294	$\uparrow 0.66$	4.29M
baseline+CBAM [14]	0.7398	0.6979	$\uparrow 0.80$	4.29M
baseline+GC [38]	0.7368	0.7212	$\uparrow 0.50$	4.29M
baseline+GAB	0.7422	0.7305	$\uparrow 1.04$	4.29M
baseline+CAB	0.7635	0.7333	$\uparrow 3.17$	3.77M
baseline+SE [37]+CAB	0.7640	0.7342	$\uparrow 3.22$	4.31M
baseline+CBAM [14]+CAB	0.7584	0.7431	$\uparrow 2.66$	4.31M
baseline+GC [38]+CAB	0.7717	0.7489	$\uparrow 3.99$	4.31M
baseline+GAB+CAB	0.7813	0.7699	$\uparrow 4.95$	4.31M

类别注意块的1)分析：我们在表I中调查了CAB的有效性。实验结果表明，与基线水平相比，CAB可以大大提高其性能(Acc和Kappa的改善程度为3.分别为17%和0.065)。我们还将CAB与其他最先进的注意块结合起来，以进行公平的比较。将CAB纳入其他注意块后，DR评分结果可得到持续改善，表明其优越性

出租车

CAB的另一个优点是模型参数的增加很小(0.54M)，在性能和计算成本之间提供了良好的权衡。为了对模型的推理速度进行定量分析，我们在DDR测试集上进行了前向传播，该测试集包含3,759张眼底图像，大小为512×512。这个模型在一个NVIDIA GTX 1080Ti GPU上进行了评估，它可以以MobileNet1.0为骨干，每秒处理75张图像，满足实时需求。

CABNet的2)分析：为了研究CAB和GAB之间的关系，我们聚合这两个块形成注意模块。与基线+CAB相比，基线+CAB+GAB(CABNet)可以持续提高准确性和Kappa评分，并在DDR数据集上取得最好的结果，证明了两个块的有效性，并表明它们是相互补充的。

我们还将我们的GAB与其他注意网络进行了比较，以证明其有效性。为了进行公平的比较，我们为每个注意块保持相同的模型参数。表I中的结果显示，与SE、CBAM和GC注意块相比，GAB在DDR数据集上获得了最好的DR评分性能，证明了其有效性。重要的是，虽然CBAM具有较强的拟合能力，但它在训练集上表现良好，但它会导致过拟合，因此在测试数据集上的表现略低于GAB。

3) CABNet中k的选择：在这一部分中，我们分析了CABNet中超参数k的影响，k是每个DR类别的特征通道数。CABNet在不同k的DDR数据集上的DR分级性能见表二。结果表明，随着k值的增加，CABNet的DR分级性能得到了提高，并达到了最佳的分级效果

表二

0 采用MOBILENET1作为DDR验证集骨干的不同kI CABNET的DR分级结果

	k = 3	k = 4	k = 5	k = 6	k = 7
Acc	0.8425	0.8496	0.8569	0.8501	0.8483
Kappa	0.8542	0.8632	0.8794	0.8678	0.8597

表三

采用不同的不平衡法进行dr分级的结果
采用DDR上的移动集1.0作为骨干的比率
数据集。m是DR 0和DR2与更多的并集
样本，1是DR 1、DR 3和DR 4的并集
样本较少。#m和#1表示这个数字
样品的m和样品的数量
分别在1。不平衡比率为
以(#m/#1)表示：1。r_m和r_l
表示Rm和1的召回率，
分别

(#M/#L):1	Method	Acc	Kappa	R_M	R_L	$\delta R_M/\%$	$\delta R_L/\%$
6:1	baseline	0.7318	0.6683	0.7930	0.3515	-	-
	CABNet	0.7813	0.7699	0.8396	0.4346	$\uparrow 4.66$	$\uparrow 8.31$
7:1	baseline	0.7265	0.6507	0.7906	0.3379	-	-
	CABNet	0.7796	0.7603	0.8363	0.4321	$\uparrow 4.57$	$\uparrow 9.42$
10:1	baseline	0.7194	0.6422	0.7903	0.2899	-	-
	CABNet	0.7723	0.7586	0.8316	0.4172	$\uparrow 4.13$	$\uparrow 12.73$
15:1	baseline	0.7102	0.6312	0.7901	0.2321	-	-
	CABNet	0.7701	0.7505	0.8304	0.4125	$\uparrow 4.03$	$\uparrow 18.04$

K被设为5。然而，当我们进一步增加k的值时，模型的分类性能会下降，主要原因是由于CABNet中的过拟合和特征冗余。因此，我们在CABNet中设置了k个=5，以获得更好的性能。

4) CABNet对不同不平衡比的影响：

为了验证CABNet对不同不平衡数据分布的影响，我们通过减少样本较少的类别的训练样本数量，使不平衡数据分布问题更加严重。如图所示。2、对于DDR数据集，DR 0和DR 2的样本较多，而DR 1、DR 3和数据的样本较少

4博士。我们用M来表示DR 0和DR 2的并集
用L表示DR 1、DR 3和DR 4与较少样本的并集。不平衡比用
(#M/#L)：1表示，其中#M和#L分别表示M中的样本数和L中的样本数。为了增加不平衡比率，我们保持DR 0和DR 2中的训练样本数量不变。对于DR 1、DR 3和DR 4，我们分别使用100%、80%、60%和40%的训练样本进行模型训练，它们分别近似对应于6: 1、7: 1、10: 1和15: 1的不平衡比。为了进行公平的比较，我们对基线和CABNet使用相同的训练样本。如表三所示，随着不平衡比的增加，基线和CABNet的性能都有所下降。然而，与基线相比，CABNet的下降幅度较小。具体来说，与不平衡比为6: 1的结果相比，当不平衡比为15: 1时，基线的性能下降了2。Acc为16%，Kappa为0.0371，而CABNet仅下降1。Acc为12%，Kappa为0.0194，这表明所提出的CABNet在不同的不平衡比率下工作良好。此外，根据6RM和6RL，通过使用CABNet，对样本较少的类别的性能改善更显著

表iv

采用移动网1.0作为DDR骨干的电缆网中使用不同辍学率的dr分级结果
验证数据集。‘r’表示辍学率，‘r = 0.0’表示所有功能都被使用
在没有辍学的训练中

	r = 0.0	r = 0.25	r = 0.5	r = 0.75
Acc	0.8465	0.8545	0.8569	0.8521
Kappa	0.8565	0.8738	0.8794	0.8645

对所有不平衡比率都有更多样本的类别。当不平衡比增加时，其意义更加明显，说明所提出的CABNet适用于极不平衡的数据。

5) CABNet中辍学率的选择：在这部分中，我们分析了CABNet中辍学率r的影响，结果见表四。结果表明，当r设置为0.5时，CABNet的分级效果最好。训练过程中的特征下降操作有两个优点。一方面，它可以减少由于训练数据不足但特征过多而导致的过拟合。另一方面，一些信息的丢失会导致更大的损失，因此网络将迫使其余的特征图学习更有区别的特征来减少损失。因此，每个特征图将学习不同的鉴别特征，从而提高CABNet的表示能力。该策略类似于一个简单的模型集成，可以有效地提高模型的DR分级性能。

6) 在DDR数据集上的不同主干：为了证明所提出的CABNet的通用性，我们采用了不同的最先进的CNN架构，它们可以分为普通网络、残差网络、密集连接网络和深度可分离的卷积网络。这些架构包括VGG16 [39]、ResNet-50 [4]、DenseNet121 [40]和Xcenet[41]。

从表V中我们可以看出，集成了CAB和GAB块的基线模型可以实现显著的性能提高，而DenseNet121则需要注意模块在DDR数据集上取得了最好的结果。为了VGG16，注意块可以大大提高分级性能，因为VGG16不包含BN层，使得在训练过程中难以收敛。注意力块可以解决这个问题。结果表明，所提出的注意模块可以应用于广泛的主干网络，并在模型参数略有增加的情况下持续提高DR分级性能。

E. 在其他DR分级数据集上的结果

除了DDR数据集外，我们还验证了所提出的方法在其他DR分级数据集上的有效性，包括Messidor和EyePACS。

1) 结果中间数据集：由于有限的眼底图像数据集（1200张图像），我们只采用这个数据集测试模型训练EyePACS数据集，有以下优点：一方面，可以避免训练数据不足引起的过拟合问题；另一方面，我们可以验证

表v

目前最先进的分类的结果
采用建议的注意事项的网络
DDR数据集上的块

Backbone	Method	Acc	Kappa	$\delta acc/\%$	#Para
VGG-16 [39]	baseline	0.6288	0.5392	-	14.71M
	baseline+GAB	0.7653	0.7429	$\uparrow 13.65$	15.52M
	baseline+CAB	0.7563	0.7449	$\uparrow 12.75$	15.26M
	CABNet	0.7701	0.7502	$\uparrow 14.13$	15.53M
ResNet-50 [4]	baseline	0.7557	0.7427	-	23.59M
	baseline+GAB	0.7696	0.7573	$\uparrow 1.39$	25.17M
	baseline+CAB	0.7685	0.7504	$\uparrow 1.28$	24.92M
	CABNet	0.7773	0.7857	$\uparrow 2.16$	25.19M
DenseNet-121 [40]	baseline	0.7669	0.7438	-	7.04M
	baseline+GAB	0.7770	0.7726	$\uparrow 1.01$	8.10M
	baseline+CAB	0.7845	0.7783	$\uparrow 1.76$	7.58M
	CABNet	0.7898	0.7863	$\uparrow 2.29$	8.12M
Xception [41]	baseline	0.7494	0.7494	-	20.87M
	baseline+GAB	0.7555	0.7595	$\uparrow 0.61$	22.45M
	baseline+CAB	0.7698	0.7562	$\uparrow 2.04$	22.20M
	CABNet	0.7757	0.7693	$\uparrow 2.63$	22.46M

表VI

的中间数据集上的四级dr分级结果
所提出的方法采用了不同的最先进的方法
骨干。这些网络都经过了训练
并在此数据集上进行了测试

Backbone	Method	Acc	Kappa	$\delta acc/\%$
MobileNet1.0	baseline	0.7791	0.7887	-
	baseline+GAB	0.7841	0.7970	$\uparrow 0.50$
	baseline+CAB	0.7916	0.8067	$\uparrow 1.25$
	CABNet	0.8325	0.8408	$\uparrow 5.34$
VGG-16	baseline	0.7625	0.7756	-
	baseline+GAB	0.7975	0.8093	$\uparrow 3.50$
	baseline+CAB	0.8033	0.8123	$\uparrow 4.08$
	CABNet	0.8275	0.8298	$\uparrow 6.50$
ResNet-50	baseline	0.7650	0.7786	-
	baseline+GAB	0.8083	0.8125	$\uparrow 4.33$
	baseline+CAB	0.8016	0.8123	$\uparrow 3.66$
	CABNet	0.8375	0.8456	$\uparrow 7.25$
DenseNet-121	baseline	0.7900	0.8014	-
	baseline+GAB	0.8116	0.8247	$\uparrow 2.16$
	baseline+CAB	0.8283	0.8324	$\uparrow 3.83$
	CABNet	0.8408	0.8723	$\uparrow 5.08$
Xception	baseline	0.7891	0.7985	-
	baseline+GAB	0.8041	0.8124	$\uparrow 1.50$
	baseline+CAB	0.8125	0.8214	$\uparrow 2.34$
	CABNet	0.8400	0.8546	$\uparrow 5.09$

在一个数据集上训练并在另一个数据集上测试的CABNet的泛化能力。我们提出了四级DR分级

在表六中的Messidor数据集上的结果。CABNet可以持续提高DR分级性能，采用DenseNet121作为骨干的模型效果最好，Acc评分为84.08%，0.8723Kappa评分。

EyePACS数据集上的2) 结果：EyePACS数据集是一个大的数据集，由于DR等级之间的类别不平衡及其在分辨率、强度和质上的大变化，它具有挑战性。表七中报告的结果显示，与基线相比，所提出的CABNet可以持续提高EyePACS上的DR分级性能。

在表V、表VI和表VII中，我们在5个不同的主干网络和3个DR分级数据集上验证了我们所提出的方法的有效性。结果表明，CABNet可以应用于广泛的骨干，并在DDR、Messidor和EyePACS数据集上达到最先进的性能，

表VII

我们的方法在眼包数据集上采用最先进的骨干的dr分级结果

Backbone	Method	Acc	Kappa	$\delta acc/\%$
MobileNet1.0	baseline	0.8421	0.8320	-
	baseline+GAB	0.8460	0.8409	$\uparrow 0.39$
	baseline+CAB	0.8589	0.8576	$\uparrow 1.68$
	CABNet	0.8668	0.8607	$\uparrow 2.47$
VGG-16	baseline	0.8159	0.8102	-
	baseline+GAB	0.8371	0.8212	$\uparrow 2.12$
	baseline+CAB	0.8464	0.8320	$\uparrow 3.05$
	CABNet	0.8588	0.8479	$\uparrow 4.29$
ResNet-50	baseline	0.8285	0.8192	-
	baseline+GAB	0.8339	0.8242	$\uparrow 0.54$
	baseline+CAB	0.8356	0.8302	$\uparrow 0.71$
	CABNet	0.8589	0.8509	$\uparrow 3.04$
DenseNet-121	baseline	0.8261	0.8201	-
	baseline+GAB	0.8482	0.8498	$\uparrow 2.21$
	baseline+CAB	0.8514	0.8535	$\uparrow 2.53$
	CABNet	0.8618	0.8678	$\uparrow 3.57$
Xception	baseline	0.8193	0.8197	-
	baseline+GAB	0.8445	0.8498	$\uparrow 2.52$
	baseline+CAB	0.8594	0.8574	$\uparrow 4.01$
	CABNet	0.8659	0.8673	$\uparrow 4.66$

证明了注意模块具有良好的泛化能力。在参数的数量和DR分级性能方面，DenseNet121获得了最好的结果，因此与其他方法相比，我们将其作为骨干。

F. 与其他最先进的方法的比较

1) 二进制类任务（中间数据集）：为了进一步衡量我们的方法的分级性能，我们在中间数据集上进行二进制DR分级，以与其他最先进的DR分级方法进行比较。请注意，我们没有在EyePACS数据集上对模型进行预训练，以进行公平的比较。我们可以看到，在之前的工作中，CANet [44]在中间数据集上取得了最好的结果。该模型是为DR和DME联合分级而设计的，并同时使用DR和DME标签进行培训。它在DR分级方面的良好表现是由于它能够捕捉到这两种疾病之间的内部关系。因此，我们也进行联合训练，以提高CABNet的性能。“联合训练”表明，我们采用CABNet作为共享特征提取的骨干，并分别添加两个单独的FC层进行DR和DME分级。从表八可以看出，我们的采用联合训练策略的方法取得了最好的性能 (AUC: 96.9%, Acc: 93.3%。在AUC、Acc和F1-Score上分别比CANet高出0.6%、0.5%和0.3%。这表明DR和DME评分任务是互补的，可以提高深度模型的学习能力。

2) 多类任务（EyePACS数据集）：我们还将我们的方法与EyePACS数据集上的其他最先进的DR分级方法进行了比较。表九中的结果表明，与其他仅使用图像级标签的方法相比，我们的CABNet可以实现最先进的结果。AFN和放大网采用注意机制学习病变图，提高DR分级性能。我们的方法不仅考虑了注意机制，还考虑了数据分布的不平衡，引入了CAB来解决这一问题，大大提高了性能。它可以观察到

表VIII

对不同方法的二进制dr分级结果

MESSIDOR数据集 (%)。“-”表示没有任何结果

在他们的论文中报道过。“jt”表示关节

训练p、r和f1表示精度，

召回率和f1分数

Method	AUC	Acc	P	R	F1	Backbone Network
Lesion Based [43]	76.0	-	-	-	-	-
Fisher Vector [43]	86.3	-	-	-	-	-
VNXX [19]	88.7	89.3	-	-	-	-
CKML [19]	89.1	89.7	-	-	-	-
Zoom-in Net [27]	95.7	91.1	-	-	-	Inception-Resnet
Dynamic feature [35]	91.6	-	-	-	-	-
CABNet (ours)	94.6	92.1	91.0	89.2	89.9	DenseNet-121 (8.12M)
CANet (JT) [44]	96.3	92.6	90.6	92.0	91.2	ResNet-50 (29.03M)
CABNet (JT, ours)	96.9	93.1	92.9	90.2	91.5	DenseNet-121 (8.12M)

表ix

博士评分与其他最先进的比较

仅在眼包数据集上的方法

图像级标签

Method	Acc	Kappa
Min-Pooling	-	0.8490
o.o	-	0.8450
RG	-	0.8390
Zoom-in Net [27]	-	0.8540
AFN [45]	-	0.8590
CABNet (ours)	0.8618	0.8678

从表九中，我们的CABNet在Kappa评分方面得到了最好的结果，这证明了其有效性。

G. CABNet可视化

为了验证模型的可解释性，更好地理解CAB和CABNet的效果，我们使用Grad-CAM [42]对结果进行了可视化。如图所示。7，从左到右，我们提供了来自DDR数据集的5张图像，分别对应于从DR 0到DR 4的5个严重级别，i.e. 无DR、轻度DR、中度DR、重度DR和增殖性DR。

GAB的结果在第三行可视化，优于在第二行不注意的模型生成的结果。对于不注意的模型，可能会突出第二行DR 0和DR 1热图中一些不相关的区域，可能不覆盖第二行DR 3和DR 4热图中所示的病变区域。可以看出，即使GAB可以获得全局注意力图，但它仍然会产生一些无用的特征，如第三行的第二列所示。GAB更强调全局注意力特征，而不是区域级特征。

经CAB细化后，如图下一行所示。7、可以对注意图进行校正，聚焦在一些明显的鉴别病变区域，粗略定位可疑病变区域，为分类结果提供了良好的可解释性，有助于临床诊断。

具体来说，对于图中第二列中显示的DR 1等具有挑战性的情况。7、CABNet产生的病变热图即使病变很小，仍然可以覆盖病变区域，说明CABNet可以捕获小的病变。




图7. GAB和CAB在DDR数据集上的一些可视化结果。我们展示了5个DR等级级别(从左到右为0-4级, i. e. 分别无DR、轻度DR、中度DR、重度DR和增殖型DR)。最上面一行提供了原始图像, 其中黄色箭头表示病变区域。第二行提供了不需要注意的热图, 第三行提供了GAB的热图, 而最下面一行显示了由CAB改进的热图。

V. 讨论

随着眼底图像采集设备和深度学习算法的发展, 自动DR筛选已成为医学图像处理领域的一个热点。深度学习方法虽然在DR评分任务上取得了良好的表现, 但在临床实践中仍存在一定的应用差距。在这项工作中, 我们提出了CABNet来解决小病变和数据分布不平衡的问题。为了提高模型的可解释性, 我们进一步获得了眼底图像中可疑病变的位置图, 从而使模型产生的结果可以帮助眼科医生做出更好的诊断。实验结果表明, 该方法可以应用于广泛的骨干技术, 并在三个公共数据集上达到了最先进的性能。

我们的方法在DR分级任务中的良好性能可以归因于两个主要组成部分, 如前面的实验部分分析, i. e. 类别注意块和CABNet, 它结合了CAB和GAB。虽然我们的方法具有良好的性能, 但仍有改进的空间。首先, 整个网络都被训练成有的

只有图像级的监督, 这使得准确定位一些小的病变区域非常具有挑战性。第二, 从临床应用的角度来看, 我们的模型可以提供评分和粗糙的可疑病变的位置区域, 而不是博士病变的类型, 如软渗出物, 硬渗出物、微动脉瘤、出血, 这很重要, 因此应该在未来的工作中得到解决。

VI. 结论和未来的工作

在本文中, 我们提出了一种结合CAB和GAB的新型CAB网。CABNet可以以端到端方式进行训练, 进行细粒度DR分级, 并通过注意模块学习鉴别特征。在三个数据集上的大量实验表明, CABNet在不同的主干网络下可以实现更好的DR分级性能, 这表明了该方法的通用性。我们未来的工作是使用生成对抗网络(GANs)来合成高质量的眼底图像。这在医学领域是至关重要的, 因为获得带注释的图像是昂贵的。因此, 我们可以设计出一个更有效的模型。

不仅提供分级评分,而且还指示病变类型。利用这些合成数据集对深度模型进行预训练,然后对真实的视网膜眼底数据集进行微调,可以进一步提高DR分级性能。

用于细粒度图像识别的卷积神经网络。CVPR,檀香山,你好,美国,7月。2017, pp. 4476 - 4484 .

参考文献

- [1] N. H. Cho等., 《IDF糖尿病地图集: 全球糖尿病估计数》
2017年的患病率和2045年的预测。 *Clin. 祈祷*, 卷。138, pp. 271 - 281, Apr. 2018.
- [2] J. 丁和T. Y. 糖尿病视网膜病变的流行病学
还有糖尿病性黄斑水肿., 卷。12日, 没有。4, pp. 346-354年8月。2012.
- [3] C. P. 威尔金森等人., “提出的国际临床糖尿病视网膜瘤-
你和糖尿病性黄斑水肿疾病的严重程度量表”, *眼科*, 卷。110, 没有。9, pp. 1677 - 1682, Sep. 2003.
- [4] K. 他, X. 张, S. 任和J. 太阳, “深度剩余学习”
图像识别, ”在程序中。CVPR, 拉斯维加斯, 内华达州, 美国, 六月。2016, pp. 770 - 778 .
- [5] S. 任, K. 他, R. 吉尔希克和J. 更快的R-CNN: 对
使用区域建议网络的实时目标检测。NIPS, 蒙特利尔, QC, 加拿大, 2015, pp. 91 - 99.
- [6] K. 他, G. Gkioxari, P. 美元和R. 吉尔希克, “面具R-CNN”, 在Proc
。ICCV, 威尼斯, 意大利, 2017年, 页。2980 - 2988 .
- [7] T. Birgui塞库, M. 希丹, J. 奥利维尔和H. 卡多, “来自
使用全卷积网络的补丁到图像分割-用于视网膜图像的应用”, “2019,
arXiv: 1904.03892. 在线可用: <http://arxiv.org/abs/1904.03892>
- [8] H. 傅, J. 程, Y. 徐, D. W. K. 黄, J. 刘和X. 曹, “关节光学”
基于多标签深度网络和极性变换的圆盘和杯分割。 *医学伊玛目*, , 卷。37日, 没有。7, pp. 1597 - 1605, 七月2018.
- [9] U. 拉格哈文德拉. 藤田, S. V. 巴达里, A. 古迪加尔, J. H. Tan和
U. R. “深度卷积神经网络, 利用数字眼底图像准确诊断青光眼”, *Inf. 科学*, 卷。441, pp. 41 - 49, 2018年5月。
- [10] H. 傅等人., “青光眼筛查的光盘感知集成网络”
眼底图像, ”IEEE反式。 *医学伊玛目*, , 卷。37日, 没有。11, pp. 2493 - 2501, 11月。2018.
- [11] X. 李, T. 庞, B. 熊, W. 刘, P. 梁和T. 王, 卷积
基于神经网络的转移学习用于糖尿病视网膜病变眼底图像分类。CISP-BMEI, 上海, 中国, 10月。2017, pp. 1 - 11.
- [12] Y. 杨, T. 李, W. 李, H. 吴, W. 风扇和W. 张, “病变检测
以及通过两阶段深度卷积神经网络对糖尿病视网膜病变进行分级。
MICCAI, 魁北克市, QC, 加拿大, 2017年, 第3页。533 - 540 .
- [13] K. 韩, Y. 王, 问。田, J. 郭, C. Xu和C. 徐, “GhostNet: 更多
“2019年, *arXiv: 1911.11907*. 在线可用: <http://arxiv.org/abs/1911.11907>
- [14] S. Woo, J. 公园, JY. .-李和我。S. Kweon, “CBAM: 卷积
阻塞注意模块, ”在Proc中。ECCV, 慕尼黑, 德国, 2018年, 第3页。3 - 19.
- [15] R. 加尔盖亚和T. “糖尿病视网膜的自动识别
你使用深度学习, ” *眼科学*, 卷。124, 没有。7, pp. 962 - 969, 七月2017.
- [16] W. 张等人., “……的自动识别和分级系统”
使用深度神经网络的糖尿病性视网膜病变系统”。.-, 卷。175, pp. 12 - 25, Jul. 2019.
- [17] J. 德拉托雷, A. 阀门和D. “一个可解释的深度学习者”
糖尿病视网膜病变疾病分级分类器, “ *神经计算*, vol ”。396, pp. 465 - 476, Jul. 2020.
- [18] M. J. J. P. 范·格林斯文, B. 范金尼肯, C. B. Hoyng, T. Theelen,
和C. I. “使用选择性数据采样的快速卷积神经网络训练: 在彩色眼底
图像出血检测中的应用”, IEEE交叉分析。 *医学伊玛目*, , 卷。35岁, 没有。5, pp. 1273 - 1284, 2016年5月。
- [19] H. H. Vo和A. Verma, “新的深度神经网络
在混合颜色空间上的视网膜病变识别, ”在Proc中说。ISM, 圣何塞,
美国加利福尼亚州, 12月。2016, pp. 209 - 215.
- [20] V. 古尔山等., “深度学习的发展和验证”
视网膜眼底照片中糖尿病视网膜病变的算法。 *美国人医学使发生联系*, 卷。316, 没有。22, pp. 2402 - 2410, 2016.
- [21] J. 傅、H. 郑和T. 梅, “仔细看看更好: 反复出现

- [22] C. 曹等人。，“三思而后行：捕捉自上而下的视觉效果具有反馈卷积神经网络的注意力。*ICCV*，圣地亚哥，智利，12月。2015，pp.2956 - 2964 .
- [23] J. 乔和H. “基于注意力的弱监督层为弱监督对象定位，”在Proc中。CVPR，长滩，加州，美国，六月。2019，pp.2219 - 2228 .
- [24] LC.-陈，Y. 杨，J. 王，W. 徐和A. L.Yuille，“注意尺度：尺度感知语义图像分割。*CVPR*，拉斯维加斯维加斯，内华达州，美国，6月。2016，pp.3640 - 3649 .
- [25] Q. 唐，F. 刘，J. 姜和Y. 张勇，“注意力引导下的连锁骗子”语义分割的文本聚合，“2020，arXiv: 2002.12041。在线可用：<http://arxiv.org/abs/2002.12041>
- [26] K. 周等人。，“多细胞多任务卷积神经网络”对于糖尿病视网膜病变的分级。EMBC，檀香山，你好，美国，七月2018，pp.2724 - 2727 .
- [27] Z. 王，Y. 阴，J. 施，W. 方，H. 李和X. 王，“缩放”净：糖尿病视网膜病变检测，在Proc。MICCAI，魁北克市，QC，加拿大，2017年，第3页。267 - 275.
- [28] K. 李，Z. 吴，KC.-彭，J. 恩斯特和Y. 傅，“告诉我哪里看：引导注意推理网络。*盐湖城CVPR* UT，美国，6月。2018，pp.9215 - 9223 .
- [29] Y. 丁等人。，“弱监督注意金字塔骗局”用于细粒度视觉分类的体积神经网络，“2020，arXiv: 2002.03353。在线可用：<http://arxiv.org/abs/2002.03353>
- [30] L. 戴等人。，“利用临床技术检测视网膜微动脉瘤”卡尔报告指导多筛选CNN。*MICCAI*，2017年，页。525 - 532 .
- [31] J. 庄，J. 蔡，R. 王，J. 张和W. 郑，“关心：类注意病变区域的不平衡数据进行分类，”在Proc。MIDL，2019，pp.588 - 597 .
- [32] J. 邓，W. 董，R. Socher，LJ.-李，K. 李和L. Fei-Fei，“ImageNet：一个大规模的分层图像数据库。CVPR，迈阿密，佛罗里达州，美国，六月。2009，pp.248 - 255.
- [33] T. 李，Y. 高，K. 王，S. 郭，H. 刘和H. 康，“诊断”对糖尿病视网膜病变筛查的深度学习算法的评估，“Inf. 科学。卷。501，pp.511-522年，10月。2019.
- [34] E. 德塞尼埃等人。，“反馈到一个公开发布的图像数据-基地：Messidor数据库，“图像肛门”。*立体声*。卷。33日，没有。3，pp.231 - 234，2014.
- [35] L. Seoud.Hurtut，J. 切尔比，F. 切里特和J. M.P. 兰洛伊斯，“红色”利用动态形状特征检测糖尿病视网膜病变筛查。*医学伊玛目*。卷。35岁，没有。4，pp.1116 - 1126，Apr.2016.
- [36] Kaggle糖尿病性视网膜病变检测竞赛。已访问：四月11，2020。在线可用：<https://www.卡格尔.糖尿病胰腺病的检测>
- [37] J. 胡，L. 沈和G. 太阳，“挤压和激发网络”，在Proc。CVPR，盐湖城，UT，美国，六月。2018，pp.7132 - 7141 .
- [38] Y. 曹，J. 徐，S. 林，F. 魏和H. “GCNet：非本地网络满足挤压-激励网络等问题。”ICCV，韩国首尔，10月。2019，pp.1971 - 1980.
- [39] K. 西蒙尼安和A. “非常深的卷积网络”对于大规模图像识别，“2014，arXiv: 1409.1556。在线可用：<http://arxiv.org/abs/1409.1556>
- [40] G. 黄，Z. 刘，L. 范德马顿，和K. Q. 温伯格，“密集”连接卷积网络。CVPR，檀香山，你好，美国，7月。2017，pp.4700 - 4708 .
- [41] F. 空间空间：深度可分离卷积的深度学习选项，”在程序。CVPR，檀香山，你好，美国，7月。2017，pp.1251 - 1258 .
- [42] R. R. Selvaraju，M. 科格斯韦尔。达斯，R. 维丹塔姆，D. 帕里克和D. Batra，“梯度：通过梯度定位从深度网络的视觉解释”，*Int. J. 压缩. Vis.*，卷。128年，没有。2，pp.336-359年，2月。2020.
- [43] R. 管道，S. 阿维拉，H. F. 杰里尼克，J. Wainer。瓦莱和A. 罗恰“除了基于病变的糖尿病视网膜病变：直接转诊方法”，IEEE J. 比奥梅德。健康格式化。卷。21日。1，pp.193 - 200，1月。2017.
- [44] X. 李，X. 胡，L. 余，L. 朱，CW.-Fu和PA.-“Canet：交叉关节糖尿病性视网膜病变和糖尿病性黄斑水肿分级的疾病关注网络。*医学伊玛目*。卷。39日，没有。5，pp.1483-1493，2020年5月。
- [45] Z. 林等人。，“一个识别糖尿病视网膜病变的框架，基于关于抗噪声检测和基于注意力的融合，”在专业课程中。云彩，格拉纳达，西班牙，2018，页。74 - 82.
- [46] A. G. 霍华德等人。，“移动网络：高效的卷积神经网络”移动视觉应用的网络，“2017，arXiv: 1704.04861。在线可用：<http://arxiv.org/abs/1704.04861>